实验6：工具调用、Agent 与 Harness 实现

课程实验报告

班级	<待填>
学号	<待填>
姓名	<待填>
日期	<待填>
仓库	<待填 GitHub/Gitee 链接>
Commit	<待填>

1. 实验目的

- 掌握工具接口定义、参数验证、权限边界和结果反馈；
- 实现一个由模型决定下一步、运行状态可查看、可终止的单 Agent；
- 编写运行时 Harness，完成上下文组织、工具执行、结果检查、停止控制与日志记录。

2.1 任务选择与边界

个人软件：本课程个人软件《跃学星球 · 声暴纪元》。本实验不直接改产品代码，而是复用实验5的知识库文档（`knowledge/*.md`，共 2 份、1372 字）作为巡检对象，做一个"知识库巡检助手"——任务小、数据固定、结果可程序核对，适合作为单 Agent 的练习场景。

任务目标：统计 `knowledge/` 下文档数量、总字数与最长文档，生成一份巡检报告`reports/report_<任务编号>.md`。

项目	内容
可用数据	`knowledge/` 下 2 个 Markdown 文档（实验5 产品手册）
可用工具	`list_docs`、`read_doc`、`doc_stats`、`write_report`（见 2.2）
停止条件	模型给出最终回答并通过验收；或达到最大步数 6；或超过总时限 180s；或连续工具错误超 3 次；或用户拒绝确认
成功标准	① `doc_stats` 至少成功调用一次；② 报告文件真实存在且非空；③ 报告正文包含 `doc_stats` 返回的文档总数
输入示例	"巡检 knowledge/ 目录下的知识库文档：统计文档总数和总字数，找出字数最多的 3 个文档，并生成巡检报告"
预期结果	生成报告，正文含"文档总数：2""总字数：1372"及最长文档排名；运行状态 `ok`

哪些步骤预设、哪些由模型决定

环节	由谁决定
工具清单、参数 Schema、白名单	程序预设（写死在 `tools.py`）
循环骨架、步数/超时/重试上限	程序预设（`harness.py`）
写操作必须人工确认	程序预设
成功标准与验收方式	程序预设（`_verify`）
先调哪个工具、`top_n` 取几、要不要读细节文档、报告写什么、何时收尾	**模型决定**
工具报错后如何修正参数	**模型决定**（程序只负责把错误回填）

权限三档

档位	操作	实现
可自动执行	`list_docs`、`read_doc`、`doc_stats` 等只读工具	校验通过即执行
必须用户确认	`write_report`（写磁盘、会覆盖同名文件）	执行前打印动作、目标路径、参数摘要，`y/N` 确认；拒绝或超时（空输入）即不执行
明确禁止	白名单外的工具名、`knowledge/` 之外的路径、绝对路径、`..` 跳转、非 `.md/.txt` 文件、直接执行模型给出的命令/代码	`tools.py` 白名单 + `_safe_path` 校验，直接返回错误

2.2 工具接口与参数约束

工具清单

工具	用途	输入字段（类型，必填）	返回结果	错误信息
`list_docs`	列出知识库文档及字数	无	`{count, total_chars, docs: [{path, chars}]}`	目录不存在 → `exception`
`read_doc`	读取单个文档	`path` (string, 必填)	`{path, chars, truncated, text}`	路径越界 → `denied`；文件不存在 → `bad_args`
`doc_stats`	统计文档规模与最长文档	`top_n` (integer, 必填, 1-10)	`{total_docs, total_chars, top:[…]}`	超范围 → `bad_args`
`write_report`	写巡检报告（**改数据**）	`content` (string, 必填, 20-6000 字)	`{path, chars, note}`	长度不符 → `bad_args`；用户拒绝 → 不执行

`doc_stats` 的 Schema（与 `tools.py` 中 `parameters` 一致）：

```
{
  "type": "object",
  "properties": {
    "top_n": {"type": "integer", "description": "返回前多少个最长文档，1-10",
              "minimum": 1, "maximum": 10}
  },
  "required": ["top_n"],
  "additionalProperties": false
}
```

约束如何执行：模型只输出"工具名 + JSON 参数"，`tools.execute()` 先查白名单，再按 Schema 逐项检查（必填、类型、`minimum/maximum`、`minLength/maxLength`、多余字段），然后才调用真实函数。绝对路径与 `..` 一律拒绝；写工具固定写到 `reports/` 下。模型无法让程序执行任意函数或命令。

超时、写数据、重复调用

工具	最长等待	是否修改数据	重复调用
三个只读工具	5s	否	结果一致，幂等
`write_report`	5s	是（写入/覆盖 `report_<任务号>.md`）	同一任务内会覆盖，只保留最后一次；跨任务因任务号不同而互不影响

上线前手工测试：`python tools.py` 打印工具表，并依次执行 1 次正确参数（`doc_stats(top_n=2)`）与 3 次错误参数（`top_n=99`、`path=../config.py`、未知工具 `rm_rf`）。实测输出见图 1：越界数值被 `bad_args` 拦下、`..` 跳转被判 `denied`、未知工具被判 `unknown_tool`，均未触达真实函数。

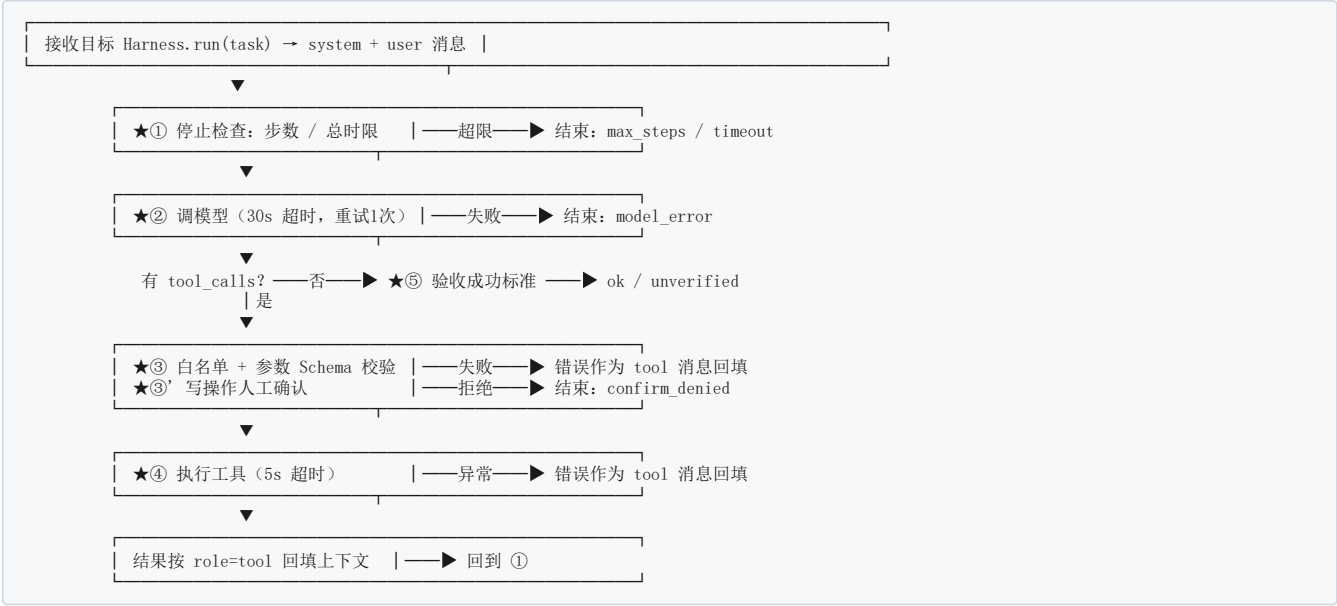
```
E:\Program Files\workspace_meme\exp6-lab>python tools.py
| 工具 | 用途 | 参数（必填*） | 是否写数据 | 需确认 |
|---|---|---|---|---|
| `list_docs` | 列出知识库 knowledge/ 下的全部 .md/.txt 文档及每个文档的字数。无参数。 | 无 | 否 | 否 |
| `read_doc` | 读取 knowledge/ 下的单个文档内容。path 为相对路径，如 '跃学星球-学生端使用指南.md'。 | path:string* | 否 | 否 |
| `doc_stats` | 统计知识库：返回文档总数、总字数，以及字数最多的 top_n 个文档。 | top_n:integer* | 否 | 否 |
| `write_report` | 把巡检报告写入 reports/ 目录，会修改磁盘数据，执行前需要用户确认。报告内容必须包含文档总数等统计结论。 | content:string* | 是 | 是 |

[正确参数] {"total_docs": 2, "total_chars": 1372, "top": [{"path": "跃学星球-教师端与家长端手册.md", "chars": 703}, {"path": "跃学星球-学生端使用指南.md", "chars": 669}]}
[错误参数] doc_stats -> bad_args: top_n 不能大于 10，实际 99
[错误参数] read_doc -> denied: 路径越界，拒绝访问：../config.py
[错误参数] rm_rf -> unknown_tool: 工具 'rm_rf' 不在允许列表 ['doc_stats', 'list_docs', 'read_doc', 'write_report'] 中
```

图 1　python tools.py：工具表与 1 次正确、3 次错误参数的实测

2.3 Agent 循环与状态

循环图（★ 为程序强制检查点）



步数定义：1 步 = 1 次模型调用（该次调用请求的所有工具执行都算在这一步内）。达到 `max_steps` 立即停止，未完成的状态记为 `max_steps`。

上下文组织：工具调用请求以 `assistant.tool_calls` 消息入栈，工具结果以 `{"role": "tool", "tool_call_id": …, "content": "<JSON>"}` 入栈，下一轮原样发给模型，不是只打印在终端。日志里能看到 `model_reply` 与 `tool_result` 交替出现。

限制：见 2.4 表；全部由 `config.py` 常量 + `harness.py` 判断执行，提示词里虽然也写了"最多 6 步"，但那只是提示，真正兜底的是程序。

图 2 是一次完整循环的终端输出（脚本化模型，动作序列固定，用于演示循环本身）：第 1 步 `doc_stats` 拿到统计，第 2 步 `write_report` 触发人工确认，确认后写入，第 3 步模型给最终回答，程序验收通过。

```
E:\Program Files\workspace_meme\exp6-lab>python main.py --mock
模型: MockModel (脚本化)
知识库: E:\Program Files\workspace_meme\exp6-lab\knowledge
允许的工具: ['doc_stats', 'list_docs', 'read_doc', 'write_report']

任务 20261109-194831-ab1b: 巡检 knowledge/ 目录下的知识库文档: 统计文档总数和总字数, 找出字数最多的 3 个文档, 并生成一份巡检报告。
限制: 最大 6 步 / 总时限 180s / 工具超时 5.0s
  run_start      task=巡检 knowledge/ 目录下的知识库文档: 统计文档总数和总字数, 找出字数最多的 3 个文档, 并生成一份巡检报告。  max_steps=6 total_limit_s=180.0
  [步 1] model_reply    attempt=1 elapsed_s=0.0 content= tool_calls=[{"name": "doc_stats", "args": "{\"top_n\": 3}"}]
  [步 1] tool_request   tool=doc_stats args={"top_n": 3}
  [步 1] tool_result    tool=doc_stats ok=true result={"total_docs": 2, "total_chars": 1372, "top": [{"path": "跃学星球-教师端与家长端手册.md", "chars": 703}, {"path": "跃学星球-学生端使用指南.md", ...(共135字符) elapsed_s=0.002
  [步 2] model_reply    attempt=1 elapsed_s=0.0 content= tool_calls=[{"name": "write_report", "args": "{\"content\": \"# 知识库巡检报告\\n\\n- 文档总数: 2\\n- 总字数: 1372\\n- 最长的文档: 跃学星球-教师端与家长端手册.md (703 ...(共179字符)
  [步 2] tool_request   tool=write_report args={"content": "# 知识库巡检报告\n\n- 文档总数: 2\n- 总字数: 1372\n- 最长的文档: 跃学星球-教师端与家长端手册.md (703 字) ; 跃学星球-学生端使用指南.md (669 字)\n\n## 巡检结论\n1. 文...(共171字符)

------------------------------------------------------------
[需要人工确认] 执行 write_report (写操作)
工具: write_report
动作: 写入 reports/report_20261109-194831-ab1b.md, 会修改磁盘数据
参数摘要: {"content": "# 知识库巡检报告\n\n- 文档总数: 2\n- 总字数: 1372\n- 最长的文档: 跃学星球-教师端与家长端手册.md (703 字) ; 跃学星球-学生端使用指南.md (669 字) \n\n## 巡检结论\n1. 文档数量与实验5知识库一致, 未发现多余文件。\n2. 单篇文档均不足 800 字, 暂不需要拆分。\n"}
------------------------------------------------------------
同意执行? (y/N) y
  [步 2] confirm        tool=write_report approved=true
  [步 2] tool_result    tool=write_report ok=true result={"path": "reports/report_20261109-194831-ab1b.md", "chars": 147, "note": "已写入; 同名文件会被覆盖, 重复调用只保留最后一次"} elapsed_s=0.001
  [步 3] model_reply    attempt=1 elapsed_s=0.0 content=巡检完成: 已生成报告, 文档总数与字数均来自 doc_stats 工具。  tool_calls=[]
  [步 3] final_answer   content=巡检完成: 已生成报告, 文档总数与字数均来自 doc_stats 工具。
  [步 3] verify         passed=true detail=报告已生成 (reports/report_20261109-194831-ab1b.md) , 且包含文档总数 2

结果: ok — 报告已生成 (reports/report_20261109-194831-ab1b.md) , 且包含文档总数 2
步数 3 / 耗时 27.35s / 错误 0 次
报告: reports/report_20261109-194831-ab1b.md
日志: E:\Program Files\workspace_meme\exp6-lab\logs\run_20261109-194831-ab1b.jsonl
```

图 2　python main.py --mock：一次完整 Agent 循环（脚本化模型）

2.4 运行时 Harness 设计与实现

职责	模块 / 函数	说明
任务输入	`main.py`（`--task`）、`Harness.run(task)`	组装 system + user 消息
上下文	`Harness.run` 里的 `messages` 列表	模型回复、工具调用、工具结果都进列表
模型调用	`models.RealModel.chat` / `Harness._call_model`	function calling；统一超时与重试
工具分发	`tools.execute` + `tools.TOOLS` 白名单	名称查表，参数校验后调用
参数与权限检查	`tools.validate_args`、`tools._safe_path`	类型/范围/多余字段/目录边界
人工确认	`Harness._run_tool` → `confirm` 回调	写操作前打印动作与影响
结果回填	`Harness.run` 里的 `role=tool` 消息	模型下一轮可见
停止控制	`RunAborted` + 循环条件	5 种停止原因，均写入日志
结果检查	`Harness._verify`	程序核对报告文件与统计数字
日志	`RunLogger`	每事件一行 JSON；结束时写 `runs.jsonl` 汇总

失败反馈：工具错误以 `{"ok": false, "error_type": …, "message": …}` 回填给模型；模型看到后自行改参数重试（用例 3 实测：`top_n=99` → 错误 → 改成 3 → 成功）；连续错误超过 3 次则结束并记 `tool_error_limit`。

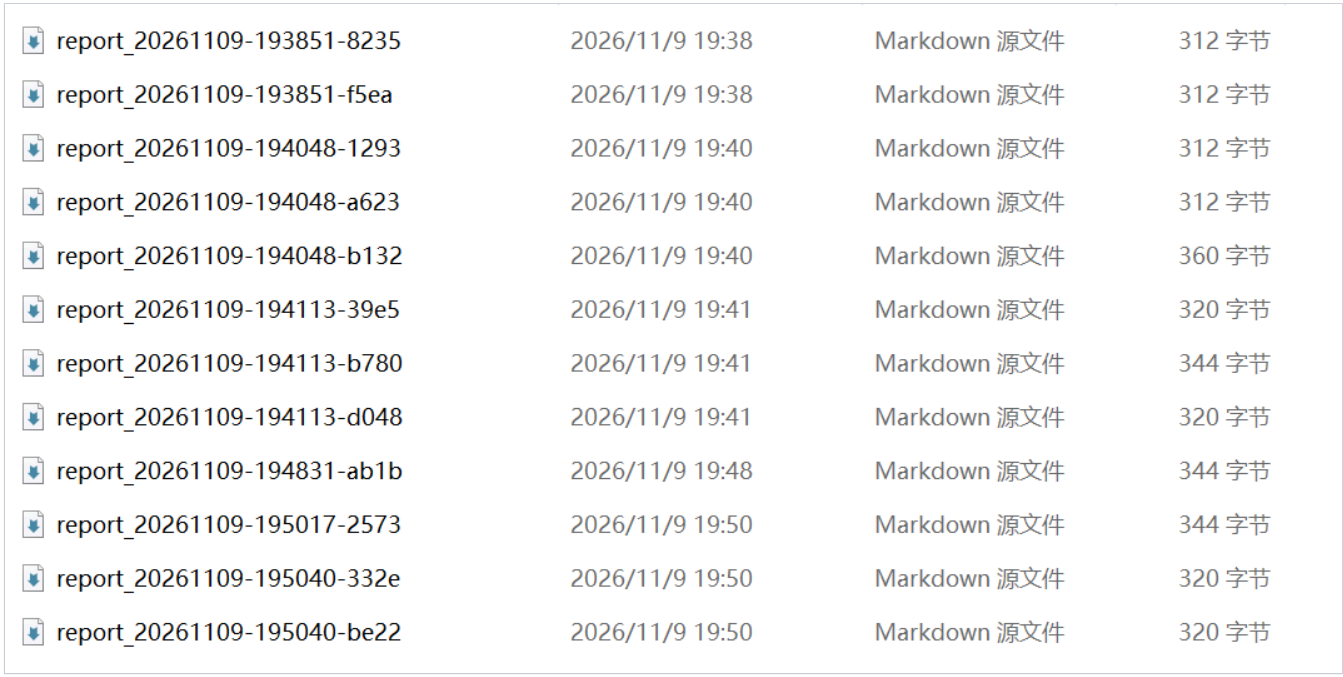
2.5 失败处理与可观测性

每次运行的记录（`logs/run_<task_id>.jsonl`，一行一事件）：

字段	含义
`task_id`	任务编号，形如 `20261109-202315-4765`
`time` / `elapsed_s`	事件时间与相对开始的秒数
`event`	`run_start` / `model_reply` / `tool_request` / `tool_result` / `confirm` / `final_answer` / `verify` / `stop`
`step`	第几步
`tool` / `args`	工具名与参数摘要（截断到 200 字符，密钥正则打码为 `sk-***`）
`ok` / `error_type` / `message`	工具结果与错误分类
`elapsed_s`	单次调用耗时

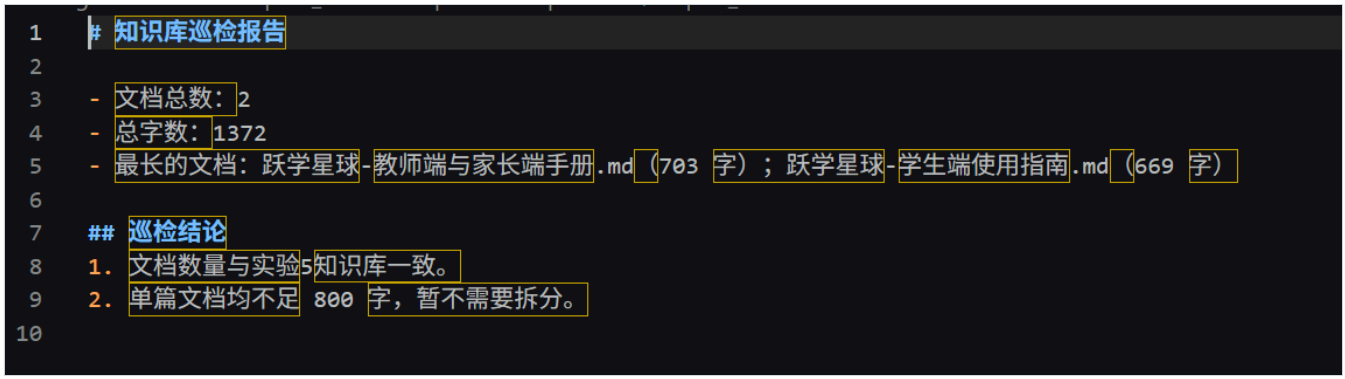
`logs/runs.jsonl` 每次运行一行汇总：状态、原因、步数、耗时、错误数、工具调用序列、报告路径。

图 3 是生成的报告文件与打开后的内容；图 4 是日志目录与 `runs.jsonl` 的汇总记录（第 6 行即密钥停用期间的 `model_error` 记录）。



report_20261109-193851-8235	2026/11/9 19:38	Markdown 源文件	312 字节
report_20261109-193851-f5ea	2026/11/9 19:38	Markdown 源文件	312 字节
report_20261109-194048-1293	2026/11/9 19:40	Markdown 源文件	312 字节
report_20261109-194048-a623	2026/11/9 19:40	Markdown 源文件	312 字节
report_20261109-194048-b132	2026/11/9 19:40	Markdown 源文件	360 字节
report_20261109-194113-39e5	2026/11/9 19:41	Markdown 源文件	320 字节
report_20261109-194113-b780	2026/11/9 19:41	Markdown 源文件	344 字节
report_20261109-194113-d048	2026/11/9 19:41	Markdown 源文件	320 字节
report_20261109-194831-ab1b	2026/11/9 19:48	Markdown 源文件	344 字节
report_20261109-195017-2573	2026/11/9 19:50	Markdown 源文件	344 字节
report_20261109-195040-332e	2026/11/9 19:50	Markdown 源文件	320 字节
report_20261109-195040-be22	2026/11/9 19:50	Markdown 源文件	320 字节

图 3-1　reports/ 下生成的报告文件



```
1  # 知识库巡检报告
2
3  - 文档总数：2
4  - 总字数：1372
5  - 最长的文档：跃学星球-教师端与家长端手册.md（703 字）；跃学星球-学生端使用指南.md（669 字）
6
7  ## 巡检结论
8  1. 文档数量与实验5知识库一致。
9  2. 单篇文档均不足 800 字，暂不需要拆分。
10
```

图 3-2　报告正文：文档总数 2、总字数 1372、巡检结论



run_20261109-194048-b132.jsonl	2026/11/9 19:40	JSONL 文件	3.25 KB
run_20261109-194048-d3d1.jsonl	2026/11/9 19:40	JSONL 文件	1.85 KB
run_20261109-194113-7b32.jsonl	2026/11/9 19:41	JSONL 文件	1.85 KB
run_20261109-194113-8d7e.jsonl	2026/11/9 19:41	JSONL 文件	1.44 KB
run_20261109-194113-39e5.jsonl	2026/11/9 19:41	JSONL 文件	3.67 KB
run_20261109-194113-8132.jsonl	2026/11/9 19:41	JSONL 文件	2.29 KB
run_20261109-194113-b780.jsonl	2026/11/9 19:41	JSONL 文件	2.73 KB
run_20261109-194113-d048.jsonl	2026/11/9 19:41	JSONL 文件	3.03 KB
run_20261109-194113-db8b.jsonl	2026/11/9 19:41	JSONL 文件	2.43 KB
run_20261109-194831-ab1b.jsonl	2026/11/9 19:48	JSONL 文件	3.24 KB
run_20261109-194936-b2dd.jsonl	2026/11/9 19:49	JSONL 文件	2.43 KB
run_20261109-195017-2573.jsonl	2026/11/9 19:50	JSONL 文件	2.73 KB
run_20261109-195040-53c9.jsonl	2026/11/9 19:50	JSONL 文件	1.85 KB
run_20261109-195040-62b6.jsonl	2026/11/9 19:50	JSONL 文件	1.44 KB
run_20261109-195040-332e.jsonl	2026/11/9 19:50	JSONL 文件	3.67 KB
run_20261109-195040-4152.jsonl	2026/11/9 19:50	JSONL 文件	2.29 KB
run_20261109-195040-be22.jsonl	2026/11/9 19:50	JSONL 文件	3.03 KB
runs.jsonl	2026/11/9 19:50	JSONL 文件	14.3 KB
test_report	2026/11/9 19:50	Markdown 源文件	1.45 KB

图 4-1　logs/ 下每次运行一个 jsonl

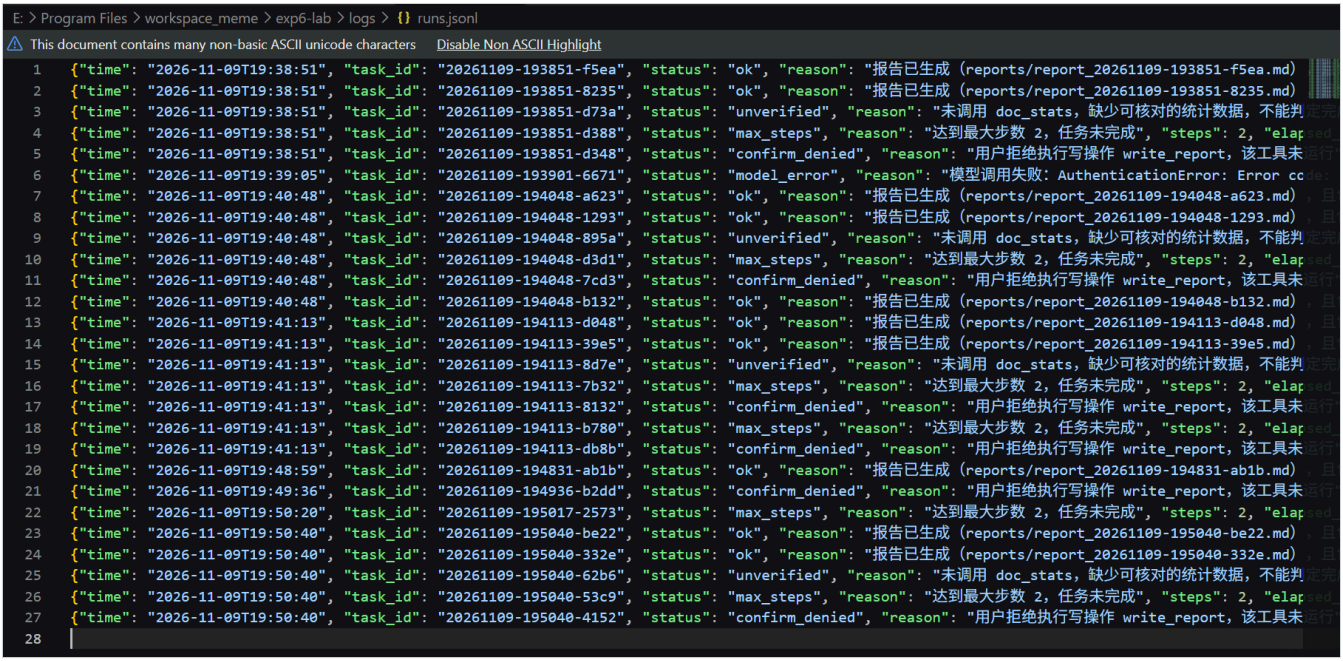


图 4-2　runs.jsonl：每次运行一行汇总（状态/原因/步数/耗时）

错误分类与处理

情况	状态	处理
参数错误	反馈后继续	返回 `bad_args` 给模型，最多 3 次，之后 `tool_error_limit`
工具异常	反馈后继续	捕获为 `exception`（含异常类型与消息），同上
工具超时	反馈后继续	`timeout`：停止等待，**不代表后台线程已停**
模型调用失败	`model_error`	重试 1 次（间隔 1s），仍失败则结束并记录原因
达到步数/时限	`max_steps` / `timeout`	立即停止，不产生报告；不重复执行已成功的写操作
用户拒绝确认	`confirm_denied`	写工具不执行，报告不产生
模型说"完成"但不满足标准	`unverified`	结束但标记未验收，理由写进日志

状态不明的写操作：`write_report` 若超时，程序不会自动重试（`MAX_TOOL_ERRORS` 内也不会盲目重发），而是先看 `reports/` 下目标文件是否存在、大小是否非零——日志里记录的`report_path` 就是用于核对的依据。这一点在 `Harness._verify` 中固化为"文件必须真实存在"。

人工确认流程：执行前打印工具名、目标路径、参数摘要 → `y/N` → 拒绝或空输入即不执行，状态记为 `confirm_denied`，模型不会再收到成功回执。

超时与取消能力：模型调用由 SDK 的 `timeout` 控制；工具调用放在单线程池里`future.result(timeout=5)`。超时只是"不再等待"，Python 无法强杀线程，后台可能仍在跑；因此本实验把写操作排在最后一步，且写完后立即验收，避免"超时后重复写"。

2.6 测试与结果分析

运行环境：Python 3.15、`openai` 3.37、通义千问 `qwen-plus`（阿里云百炼 OpenAI 兼容接口）。五类情况共 7 条记录，全部通过：

#	用例	输入 / 触发方式	预期行为	实际结果	判断
1	正常完成（真实模型）	巡检任务，确认 `y`	生成报告并通过程序验收	`status=ok`，5 步，13.1s；`doc_stats`→`read_doc`×2→`write_report`→最终回答	通过
2	正常完成（脚本复现）	同任务，`--mock`	动作序列固定、可重复	`status=ok`，3 步	通过
3	参数错误	模型给 `top_n=99`	返回 `bad_args`，模型修正后完成	`status=ok`，4 步，1 次 `bad_args`	通过
4	工具异常	工具内部抛 `OSError`	`exception` 反馈给模型，结束并说明原因	`status=unverified`，2 步	通过
5	达到步数上限	`--max-steps 2`	第 2 步后强制停止	`status=max_steps`，2 步	通过
6	人工确认-拒绝	写报告时输入 `n`	不执行写工具、不产生报告	`status=confirm_denied`，2 步	通过
7	模型调用失败	账户侧停用密钥（复现 401）	重试 1 次后结束并记录原因	`status=model_error`，1 步	通过

分析：

- 用例 1 与用例 2 动作不同（真实模型读了 2 份文档共 5 步，脚本固定 3 步），

说明"下一步做什么"确实由模型决定，而不是程序写死的流水线。

- 用例 3 说明错误反馈闭环有效：模型读到了 `bad_args` 文本，把 `top_n` 从 99 改成 3。
- 用例 4 说明"工具异常"与"任务未完成"是两件事：异常被正确反馈，但因为没有统计数据，

验收判 `unverified`，而不是模型自称完成后就判成功。

- 用例 5、6 说明停止与确认规则由程序执行，与模型意愿无关；用例 7 说明模型侧失败

也会被重试并留下 `model_error` 记录。

局限：

1. 未接个人软件的运行环境，巡检对象是本仓库的知识库副本，不是产品线上数据；
2. 工具超时只是停止等待，无法真正杀掉后台线程，写操作超时后的状态核对依赖人工看文件；
3. 单 Agent、单轮任务，没有多轮对话与记忆；
4. 成功标准是"报告存在 + 含文档总数"这类简单规则，复杂任务需要更细的验收规则。

改进计划：把 `write_report` 改为先写临时文件再原子替换，避免半写；增加 `--dry-run` 与"时间上限"用例；把报告结构改成模板填充并在验收时校验章节完整性。

3 操作记录

截图均来自实际运行，按出现顺序编号；原图保存在 `图片/` 目录。

编号	文件	内容与说明
图 1	图1_python tools.py.png	工具表 + 1 次正确参数、3 次错误参数（bad_args / denied / unknown_tool）
图 2	图2_python main.py --mock.png	脚本化模型的一次完整循环：3 步、确认提示、验收 ok
图 3-1	图3_生成的巡检报告_1.png	reports/ 下每个任务一个报告文件
图 3-2	图3_生成的巡检报告_2.png	报告正文：文档总数 2、总字数 1372、两条结论
图 4-1	图4_逐事件日志_1.png	logs/ 下每个任务一个 run_<id>.jsonl
图 4-2	图4_逐事件日志_2.png	runs.jsonl 汇总：状态、原因、步数、耗时（含 401 那次 model_error）
图 5	图5_五类测试结果表.png	run_tests.py 生成的五类测试表（logs/test_report.md）
图 6	图6_python check_key.py 的输出.png	密钥自检：认证成功，模型回复"成功"
图 7	图7python main.py 的完整输出.png	真实模型完整运行：5 步、人工确认、 结果：ok

实验6 测试记录（2026-11-09T19:50:40）

#	输入	预期行为	实际结果	判断	日志
1	正常完成	巡检知识库并生成报告（用户同意写操作）	ok + 应当校验通过：报告存在且含文档总数	status=ok, 步骤 3, 耗时 0.0s	通过	`run_20261109-195040-be22.jsonl`
2	参数错误	模型先给了越界参数 top_n=99，应当被程序拦下并反馈	ok + 第一次调用应返回 bad_args，模型修正后完成	status=ok, 步骤 4, 耗时 0.0s; 工具错误: ['bad_args']	通过	`run_20261109-195040-332e.jsonl`
3	工具异常	工具内部抛 OSError（模拟磁盘故障）	unverified + 异常应被捕获为 error 反馈给模型，任务结束且说明原因	status=unverified, 步骤 2, 耗时 0.0s; 工具错误: ['exception']	通过	`run_20261109-195040-62b6.jsonl`
4	达到步数上限	模型反复调用工具，超过 max_steps=2	max_steps + 程序应在第 2 步后强制停止，不能无限循环	status=max_steps, 步骤 2, 耗时 0.0s	通过	`run_20261109-195040-53c9.jsonl`
5	人工确认-拒绝	写报告前用户拒绝确认	confirm_denied + 拒绝后不应执行写工具，也不应生成报告文件	status=confirm_denied, 步骤 2, 耗时 0.0s	通过	`run_20261109-195040-4152.jsonl`

共 5 项，通过 5 项。正常流程的真实模型调用见 `logs/runs.jsonl` 中 `python main.py` 的记录。

图 5　run_tests.py 生成的五类测试结果表（logs/test_report.md）

```
E:\Program Files\workspace_meme\exp6-lab>python check_key.py
密钥来源: 环境变量 / .env（当前值 sk-ws-...yCbg（长度 115））
接口地址: https://dashscope.aliyuncs.com/compatible-mode/v1
模型: qwen-plus

认证成功，模型回复：成功
```

图 6　check_key.py：密钥可用性自检



图 7　真实模型运行：5 步完成，写报告前人工确认，结果 ok

4 实验小结

这次实验最直接的体会是："让模型调工具"和"让模型写答案"是两种完全不同的工程问题。前者要回答的是——模型说要调 `doc_stats`，程序凭什么信它？本实验的答案是三层：白名单决定"能不能调"，Schema 决定"参数合不合法"，路径解析决定"能碰到哪些文件"。三层都在代码里，不写在提示词里，因为提示词是可以被模型"聊"过去的，而 `raise ToolError` 不会。

第二个体会是循环本身很轻，外围很重。`Harness.run` 的核心不过二十行，但真正让它可交付的是那些"扫兴"的东西：步数上限、超时、错误计数、人工确认、日志和验收。尤其是验收——模型在第 5 步说"报告已写入"，程序仍然去磁盘上确认文件存在、内容里确实有 `doc_stats` 返回的数字，才判 `ok`。把"模型自称完成"和"任务真的完成"分开，是这次最实用的一条经验。

第三个体会是边界情况比正常流程更考验设计。工具超时只是"不再等待"，线程可能还在跑；写操作如果状态不明，先查文件再决定是否重试，而不是直接重发。这些在代码里只是几行判断，但报告里必须写清楚，因为它们决定了这个 Agent 能不能被放心地用在实际软件上。

目前的实现是一个单 Agent、单任务的巡检小工具，局限也清楚：验收规则简单、没有多轮对话、工具超时无法真正取消。后续如果接到《跃学星球》的实际内容流水线上，会先补"报告结构校验"和"写操作原子化"，再考虑多工具并行。